Proyecto centinela Fase 1: Homicidios en Medellín

DECANATURA DE DIVISIÓN DE EDUCACIÓN ABIERTA Y A DISTANCIA
FACULTAD DE ESTADÍSTICA

Tomás Rendón Bustamante
Juan Sebastián Gamba Aguirre

Maestría en Ciencia de Datos

Centro de Atención Universitario Bogotá
8 de noviembre de 2026

TABLA DE CONTENIDO

1. INTRODUCCION 5

2. DESARROLLO DE LA ACTIVIDAD 5

3. Conclusiones ..... ¡Error! Marcador no definido.

4. REFERENCIAS 14

1. INTRODUCCION

El MLP de la v1 no distinguía los meses de repunte mejor que el azar: en la prueba (2023-01 a 2023-11) su PR-AUC fue 0,188 frente a una prevalencia de alertas de 19,0 %. Al comparar con otro cuaderno del curso vimos que la v1 no le daba a la red el percentil 75 con el que se define la etiqueta y llevaba cuatro entradas redundantes. La v2 corrige eso y otros tres detalles (sección 5). El ajuste mejora de forma modesta el PR-AUC de validación (de 0,251 a 0,276, promedio de cinco semillas), pero en la prueba (0,208 ± 0,034; 0,204 con el promedio de las semillas) sigue sin distinguirse del azar (valor p ≈ 0,49), y la semilla 42 quedó incluso por debajo de él (0,180). Recomendamos no usar este sistema para decisiones operativas; queda como línea base documentada para la Fase 2.

2. DESARROLLO DE LA ACTIVIDAD

2.1 Problema y cliente.

El cliente simulado es la Secretaría de Seguridad y Convivencia de Medellín, que necesita anticipar meses con aumentos inusuales de homicidios registrados para apoyar decisiones preventivas verificadas por personas. La unidad de análisis es comuna o corregimiento por mes. Un territorio c tiene alerta en el mes m si H(c,m) ≥ 2 y H(c,m) supera el percentil 75 de sus 12 meses anteriores; el modelo predice m con información hasta m−1. Es un umbral académico: compara territorios de magnitudes distintas y evita que un solo caso dispare alertas, pero pierde la magnitud del aumento y no es una regla oficial.

2.2 Datos.

La serie sale únicamente del consolidado agregado de la Alcaldía de Medellín (SISC/MEData, datos.gov.co, licencia CC BY-SA 4.0), descargado el 2026-11-03; no incluye datos de personas (el Excel de víctimas se retiró del proyecto). El archivo tiene 23.164 filas × 4 columnas (2003-01 a 2023-11) y 0 % de faltantes. Los homicidios son

4.071 filas (18.593 casos) en 21 territorios (16 comunas y 5 corregimientos). El mismo territorio llega como «1» y «1.0» (se unifica) y hay 472 filas «SIN DATO», ninguna de homicidio. El archivo no trae filas con cero: se rellenan 1.200 de 5.271 pares territorio-mes (22,8 %) y se declara que cero registrado no equivale a cero real.

Hallazgos del EDA y decisiones. (i) Desbalance de ≈ 81/19 → la métrica principal es el PR-AUC y el recall de la alerta, no la exactitud. (ii) Conteos pequeños (mediana 3, máximo 35 por fila) → la etiqueta exige H ≥ 2. (iii) Es una serie en el tiempo → partición cronológica, con el escalador ajustado solo con entrenamiento. (iv) El % de meses con alerta va de ≈ 1 % (territorio 50) a ≈ 25 % (territorio 4) → el territorio entra como variable

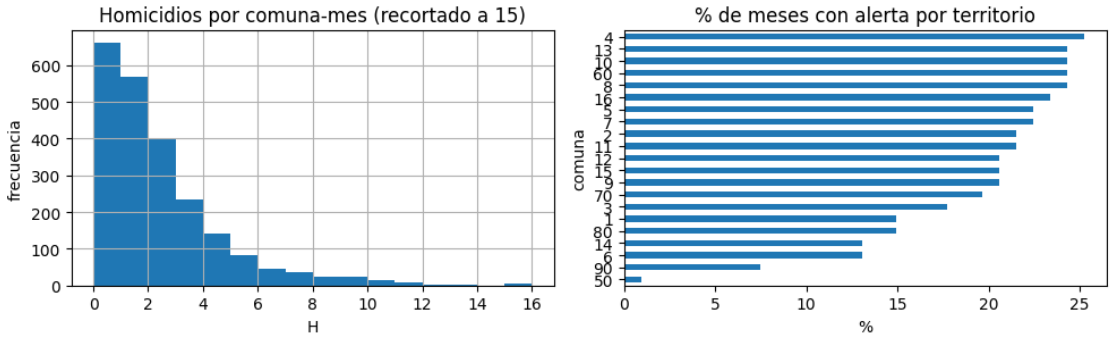


Figura 1. Distribución de los conteos mensuales (izquierda) y porcentaje de meses con alerta por territorio (derecha

2.3 Modelo y entrenamiento (v1)

Cada rasgo del mes m usa solo meses hasta m−1. En la v1: rezagos 1–3, sumas y medias móviles de 3, 6 y 12 meses, cambio entre rezagos, mes cíclico (seno y coseno) y territorio (one-hot); en total 33 entradas. La partición es cronológica por mes objetivo: entrenamiento 2015-01 a 2020-12 (1.512 observaciones, 285 alertas, 18,8 %), validación 2021-01 a 2022-12 (504 observaciones, 96 alertas, 19,0 %) y prueba 2023-01 a 2023-11 (231 observaciones, 44 alertas, 19,0 %). El escalador se ajusta solo con entrenamiento y el umbral de alerta se elige solo en validación.

El MLP tiene dos capas ocultas (16 y 8 neuronas) con ReLU, que aporta la no linealidad sin la cual apilar capas equivaldría a una sola transformación lineal. La salida

es un logit con BCEWithLogitsLoss (la sigmoide solo se aplica al evaluar). Se entrena con Adam (tasa 1e-3), lotes de 64, parada temprana con paciencia 15 y semilla 42, con el bucle explícito forward → pérdida → zero_grad → backward → step.

Sobreajuste inducido y corregido. Con 300 filas de entrenamiento y redes grandes la validación toca su mínimo muy pronto y luego sube mientras el entrenamiento cae a casi 0 (Figura 2): la red memoriza. El Dropout y una red menor reducen la brecha, pero no la eliminan; lo que evita el daño es parar temprano y restaurar los pesos de la mejor época.

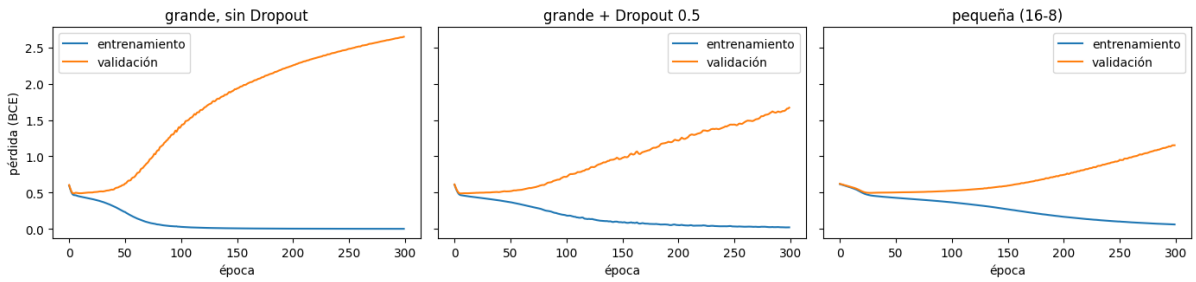


Figura 2. Pérdida de entrenamiento y de validación por época en las tres corridas con 300 filas.

Corrida (300 filas)	Época del mínimo de validación	Pérdida mínima de validación	Brecha final (val − train)
Grande (128-64), sin Dropout	5	0,4888	2,6479
Grande + Dropout 0,5	6	0,4886	1,6498
Pequeña (16-8)	28	0,4961	1,0916

Modelo final de la v1. Con el entrenamiento completo y parada temprana, los tres candidatos empatan en la práctica: 16-8 con Dropout 0,2 (mejor época 28, pérdida 0,4787), 16-8 sin Dropout (elegido; mejor época 70, pérdida 0,4748) y 64-32 con Dropout 0,2 (mejor época 29, pérdida 0,4767). Predecir siempre la prevalencia de validación da una pérdida de ≈ 0,487, así que el modelo mejora apenas ≈ 2,5 %.

2.4 Resultados de la v1 y errores

Con el umbral 0,23 elegido en validación, en la prueba (231 observaciones, 44 alertas reales):

Modelo	Exactitud	Precisión (alerta)	Recall (alerta)	F1 (alerta)	PR-AUC
Clase mayoritaria	0,810	0,000	0,000	0,000	—
Regla del conteo previo	0,251	0,197	0,955	0,327	0,168
MLP v1	0,550	0,174	0,364	0,235	0,188

El MLP v1 no supera al azar. Con 19,0 % de alertas, un clasificador sin señal obtiene un PR-AUC cercano a ese valor, y el MLP logra 0,188. La clase mayoritaria alcanza la mayor exactitud (0,810), pero nunca avisa. La regla del conteo previo alerta en el 92,2 % de los meses: su recall de 0,955 es alto por construcción y su F1 de 0,327 es casi el de alertar siempre (0,320; auditoría en la sección 10 del cuaderno). Matriz de confusión del MLP v1: 16 verdaderos positivos, 28 falsos negativos, 76 falsos positivos y 111 verdaderos negativos (Figura 3). Por territorio (0 a 5 alertas reales cada uno en 11 meses): el territorio 8 (5 alertas reales) detectó 3; los territorios 3 y 6 (4 cada uno) no detectaron ninguna. Son indicios, no un ranking.

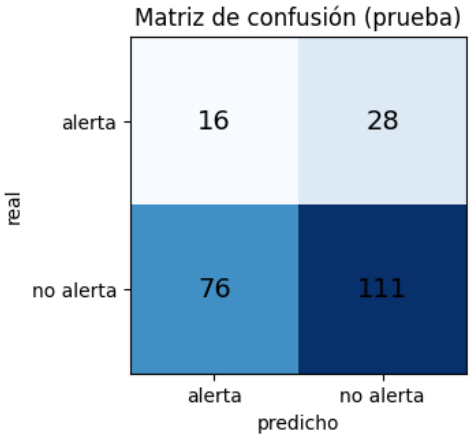


Figura 3. Matriz de confusión del MLP v1 en la prueba (filas: real; columnas: predicho).

2.5 Ajuste v2

Comprobar si el MLP mejora al corregir debilidades concretas de la v1 y medir con más cuidado si la mejora es real o es ruido. No se cambió el problema, la etiqueta ni las particiones.

Cambio	Por qué	Objetivo
Se agrega p75_12 (percentil 75 de los 12 meses anteriores) como entrada	La etiqueta compara H con ese valor y la v1 no se lo daba a la red. Se calcula solo con meses anteriores: no hay fuga.	Que la red reciba la información con la que se define la etiqueta
Se quitan suma3, suma6, suma12 y delta	Son combinaciones exactas de otras entradas (suma = media × ventana; delta = lag1 − lag2) y no aportan información nueva.	Menos ruido: 30 entradas en vez de 33

Cambio	Por qué	Objetivo
weight_decay 1e-4, paciencia 20, mejora mínima 1e-4	Frena pesos grandes y evita que la parada temprana dependa de diferencias ínfimas.	Entrenamiento más estable
Umbral por presupuesto: alerta el 20 % de los meses con mayor probabilidad en validación	El umbral que maximiza F1 en validación es inestable con pocas alertas.	Umbral reproducible y fácil de explicar
Cinco semillas (7, 21, 42, 73, 101)	Una sola corrida no dice cuánto varía el resultado.	Medir la variación entre ejecuciones
Líneas base de igual número de alertas, «alertar siempre» y prueba de permutación	La regla de la v1 alertaba en el 92 % de los meses: su recall alto no era una comparación justa.	Saber si el MLP supera al azar y a reglas simples

Se evaluó Misma partición cronológica; escalador ajustado solo con entrenamiento; el umbral (percentil 80 de las probabilidades de validación) se fija en validación y se aplica a la prueba. El valor p sale de una prueba de permutación (se barajan las etiquetas 2.000 veces y se cuenta cuántas veces el azar iguala el PR-AUC observado) y el intervalo de un bootstrap sobre los meses. Declaración sobre la prueba: la v1 ya la había usado una vez; la v2 la usa por segunda vez con un diseño fijado antes de ver su resultado. Ninguna decisión (rasgos, umbral, semilla representativa) se tomó

mirando la prueba, y la semilla 42 se eligió por ser la del cuaderno, no por su desempeño. Aun así, la repetición reduce el valor de la prueba como evidencia independiente.

Resultado:

Configuración (promedio ± desviación de 5 semillas)	PR-AUC validación	PR-AUC prueba	Pérdida de validación
v1: rasgos y entrenamiento originales (33 entradas)	0,251 ± 0,017	0,183 ± 0,011	0,4781
v2a: solo los rasgos nuevos (30 entradas)	0,280 ± 0,010	0,214 ± 0,037	0,4725
v2: rasgos nuevos + weight_decay + paciencia 20	0,276 ± 0,016	0,208 ± 0,034	0,4726

Tabla 1. Comparación v1 / v2 con la misma partición (ejecución en Colab con PyTorch). Prevalencia de alertas: 0,190 en validación y en prueba.

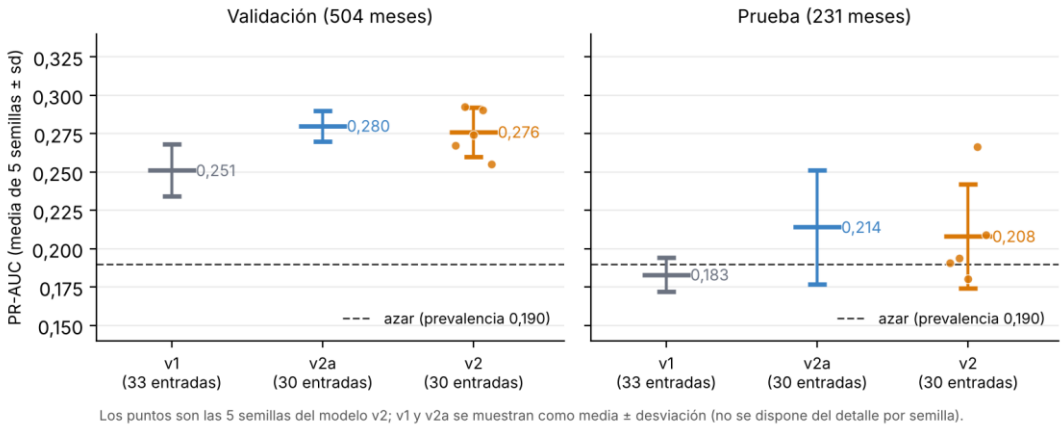


Figura 4. PR-AUC de la v2 por semilla (puntos), media ± desviación de cada configuración (barras) y nivel del azar (línea punteada).

Modelo	Conjunto	PR-AUC	Intervalo 95 %	Prevalencia	Valor p (azar)
v2, semilla 42	Validación	0,274	0,216 – 0,364	0,190	0,002
v2, semilla 42	Prueba	0,180	0,133 – 0,260	0,190	0,821
v2, promedio de 5 semillas	Validación	0,277	0,215 – 0,357	0,190	0,004
v2, promedio de 5 semillas	Prueba	0,204	0,149 – 0,305	0,190	0,490

Tabla 2. Comparación con el azar (prueba de permutación e intervalo bootstrap).

Modelo (prueba)	Alertas	Exactitud	Precisión	Recall	F1	PR-AUC
Clase mayoritaria (nunca alerta)	0	0,810	0,000	0,000	0,000	—
Alertar siempre	231	0,190	0,190	1,000	0,320	—
Regla del conteo previo, umbral por F1 (v1)	213	0,251	0,197	0,955	0,327	0,168
Regla del conteo previo, 20 % de alertas	40	0,697	0,175	0,159	0,167	0,168
MLP v1 (umbral 0,23)	92	0,550	0,174	0,364	0,235	0,188
MLP v2, semilla 42, 20 % de alertas	37	0,675	0,081	0,068	0,074	0,180

Tabla 3. Líneas base justas en la prueba. Matriz del MLP v2 (semilla 42, umbral 0,269): 3 verdaderos positivos, 41 falsos negativos, 34 falsos positivos y 153 verdaderos negativos.

Lectura nueva tras el ajuste:

- El cambio de rasgos explica casi toda la mejora. v2a y v2 tienen casi el mismo PR-AUC de validación (0,280 y 0,276); weight_decay y la paciencia no la modifican de forma apreciable.

- En validación hay señal; el PR-AUC de la v2 se distingue del azar (p = 0,004 con el promedio de semillas). Es una señal débil: el F1 de validación con el 20 % de alertas es 0,31 en promedio (con tantas alertas como casos reales, la precisión es casi igual), es decir, ≈ 7 de cada 10 alertas son falsas. Esa cifra está algo inflada porque la parada temprana y la elección de época usan la misma validación.

- En prueba no hay evidencia de señal: PR-AUC 0,204 con el promedio de semillas, valor p ≈ 0,49 y un intervalo (0,149 a 0,305) que incluye la prevalencia. El resultado varía mucho entre semillas (de 0,180 a 0,267). La semilla 42, que se fijó de antemano como representativa, quedó en 0,180: con 37 alertas emitidas se esperarían ≈ 7 aciertos por azar y acertó 3 (p = 0,82). El umbral de validación (0,269) produjo 37 alertas en prueba, menos del 20 % de los meses: las probabilidades de la prueba salieron algo más bajas. Con 44 alertas reales la prueba no tiene poder para detectar una mejora de este tamaño: no se puede afirmar ni que el modelo sea inútil ni que sirva.

- Frente a la regla simple con un número parecido de alertas, el MLP v2 con la semilla 42 acierta 3 de 37 alertas (precisión 0,081) y la regla 7 de 40 (0,175). Con las cinco semillas, la precisión del MLP en prueba va de 0,081 a 0,235 y su promedio (0,173) es casi igual al de la regla: el MLP no supera a la regla simple.

2.5 Decisión

Se mantiene la recomendación: no usar este modelo para decidir ni para priorizar territorios. Con el umbral de la v1, 76 de 92 alertas fueron falsas y 28 de 44 repuntes

reales no se avisaron; con el presupuesto de la v2 (semilla 42), 34 de 37 alertas fueron falsas (91,9 %) y 41 de 44 repuntes no se avisaron (93,2 %).

Error	**Consecuencia para el cliente**	**Magnitud en la prueba (v1 / v2, semilla 42)**
Falso positivo	Estigma territorial y gasto de recursos en un territorio sin repunte	76 de 92 alertas / 34 de 37 alertas
Falso negativo	Un repunte no avisado y sin prevención	28 de 44 repuntes / 41 de 44 repuntes

2 REFERENCIAS

Alcaldía de Medellín, Secretaría de Seguridad y Convivencia, SISC. (s. f.). Consolidado cantidad de casos criminalidad en comunas por año y mes [Conjunto de datos]. Datos Abiertos Colombia. https://www.datos.gov.co/dataset/Consolidado-cantidad-de-casos-criminalidad-en-comu/gcyu-chif

Guío Español, A., Tamayo Uribe, E. y Gómez Ayerbe, P. (2021). Marco ético para la inteligencia artificial en Colombia (Versión 1). Consejería Presidencial para Asuntos Económicos y Transformación Digital, Presidencia de la República de Colombia. https://minciencias.gov.co/sites/default/files/marco-etico-ia-colombia-2021.pdf

NASA VIIRS Land Science Investigator-led Processing System. (2025). VIIRS/NPP Lunar BRDF-Adjusted Nighttime Lights Monthly L3 Global 15 arc second Linear Lat Lon Grid (Versión 2) [Conjunto de datos]. NASA LAADS DAAC. https://doi.org/10.5067/VIIRS/VNP46A3.002

Departamento Administrativo de Planeación, Alcaldía de Medellín. (s. f.). Límite político administrativo: comunas y corregimientos [Servicio cartográfico]. https://www.medellin.gov.co/servidormapas/rest/services/mapas_nacionales/VC_Limite_Politico_Admtivo/MapServer/1